[Reliable AI Assignment1]

2022480012 우지성

MNIST (Epsilon)		0.05	0.1	0.2	0.3
Untargeted	FGSM	1.33%	14.00%	51.33%	86.00%
	PGD	4.00%	26.00%	96.67%	100.00%
Targeted	FGSM	0.00%	0.67%	10.00%	36.67%
	PGD	0.00%	1.33%	69.33%	100.00%

CIFAR10 (Epsilon)		0.05	0.1	0.2	0.3
Untargeted	FGSM	84.67%	84.00%	88.67%	89.33%
	PGD	100.00%	100.00%	100.00%	100.00%
Targeted	FGSM	22.00%	20.00%	18.00%	20.67%
	PGD	100.00%	100.00%	100.00%	99.33%

(150 Sample image)

Why are some attacks more effective than others?

우선 두 공격기법 간의 우위를 다루어보자. 동일한 Epsilon 하에서 FGSM의 공격보다 PGD의 공격의 성공률이 훨씬 높았다. 이 때 공격이란, 동일한 비용을 가지고 있으며, 공격 지점에서 Epsilon만큼 떨어져있는 정사각형 거리 내 특징공간 내 취약지점 하나를 선정하는 행위로 정의할 수 있을 것이다. (혹은 Targeted된 공격기법에서는, 특징공간 내 신경망이 Target Label로 판정하는 지점을 선정하는 행위라고 할 수 있다.) 이 관점에서 FGSM과 PGD를 살펴보자. FGSM은 sign크기의 Epsilon만큼 떨어진 지점을 취하게 된다. 그 결과 Epsilon의 가장자리부분에 취약지점이 없는 경우, 공격에 실패함을 알 수 있다. 한번의 공격시도 내에 공격지점을 선정하는데 실패한다면 공격에 완전히 실패하는 것으로 볼 수 있다. 이에 반해 PGD는 각 지점에 대해 기울기를 Iterative하게 연산하여 공격을 수행하며, 위 방식으로 인해 꼭 Epsilon 지점의 끝이 아니더라도 공격 성공지점으로 도착할 확률이 높아진다. 위 차이로 인해 FGSM이 PGD에 비해 빠르지만 실패확률이 높은 공격 방식인 것이다. 이를 실제로 논증하는 것은, CIFAR10의 예시를 들 수 있을 것이다. CIFAR10의 데이터 특성 상, 많은 Feature가 존재하며, 많은 Feature를 학습한다는 사실은, Loss Surface가 Non-Convex할 가능성을 논증하므로, 최대의 Epsilon 비용을 사용하지 않고도 내부 취약지점만 잘 찾는다면, 이를 이용하여 높은 성공률로 공격해낼 수 있다고 추론할 수 있다. 이는 Epsilon 0.05의 PGD의 성능이 Epsilon 0.3의 FGSM을 압도한다는 것을 보면 이해할 수 있으며, 상대적으로 특징공간의 차원이 작은 Mnist 환경에서 작은 Epsilon의 성공률이 적은 것으로 이를 비교해볼 수 있다.

How does ε affect the trade-off between attack success and perturbation visibility?
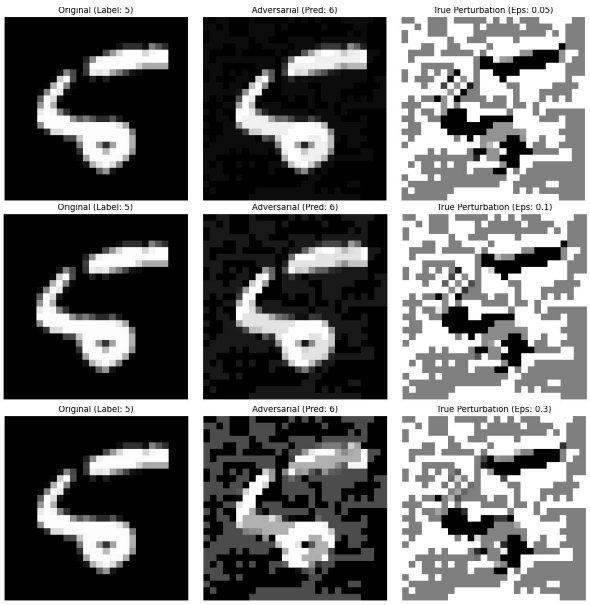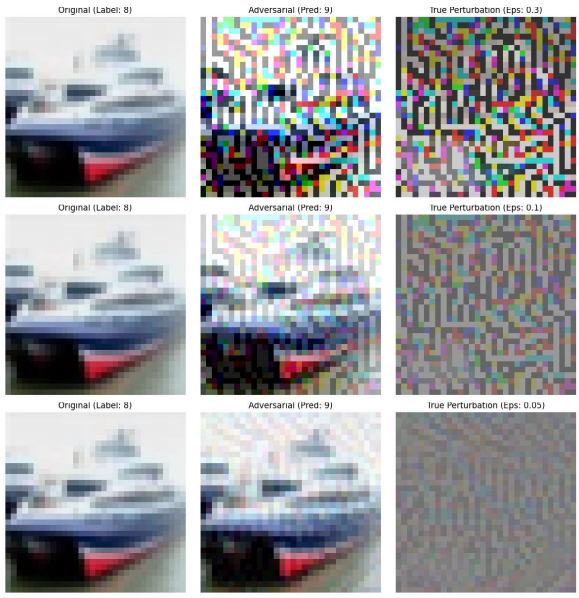
우측의 Mnist 시각화를 본다면 아주 명확하게 파악이 가능하다. 표에서 파악이 가능하듯이, Epsilon의 크기가 커진다면 성공률이 매우 커진다. 이는 공격할 자원이 더 많아진다는 점에서 명확하다. 더 큰 Epsilon 공간을 탐색한다는 의미이기도 하니 말이다. 하지만 그에 반해 가시적인 섭동이 포착되기도 한다. 이는 시각화 해둔 중간 이미지 (기존 이미지 + Noise)를 참조하면 알 수 있는데, Epsilon 0.05의 경우, 인간의 육안으로는 포착하기 어려운 Noise를 만들어냈으나, 큰 Epsilon (0.1, 0.3)을 통해 공격한 이미지는 육안으로 보기에도 Noisy한, 적대적 예제임을 파악할 수 있게 된다. 이는 당연히, 두 공격방법이, 가장 Loss를 많이 변화시키는 지점을 찾아내는 기법이고, Epsilon을 많이 활용할수록 (= Image에 Noise를 더 많이 넣을수록) 모델이 교란될 수 있는 이미지를 만들어내기 쉬우며, 특정 크기 이상의 Noise는 인간의 눈에도 포착되기 쉽기 때문이다.